

# 尚硅谷大数据技术之 Hadoop (入门)

(作者: 尚硅谷大数据研发部)

版本: V3.3

## 第1章 Hadoop 概述

## 1.1 Hadoop 是什么

→ Hadoop是什么

分布式存储:每台服务器存储一部分,多台服务器完成一个

- 1) Hadoop是一个由Apache基金会所开发的分布式系统基础架构。
- 2) 主要解决,海量数据的存储和海量数据的分析计算问题。
- 3)广义上来说, Hadoop通常是指一个更广泛的概念——Hadoop生态圈。



让天下没有难学的技术

## 1.2 Hadoop 发展历史(了解)



#### Hadoop发展历史



1) Hadoop创始人Doug Cutting,为了实现与Google类似的全文搜索功能,他在Lucene框架基础上进行优化升级,查询引擎和索引引擎。



Hadoop创始人Doug Cutting

- 2) 2001年年底Lucene成为Apache基金会的一个子项目。
- 3)对于海量数据的场景, Lucene框架面对与Google同样的困难, 存储海量数据困难, 检索海量速度慢。
- 4) 学习和模仿Google解决这些问题的办法 : 微型版Nutch。
- 5)可以说Google是Hadoop的思想之源(Google在大数据方面的三篇论文)

GFS --->HDFS

Map-Reduce --->MR

BigTable --->HBase

让天下没有难学的技术





### Hadoop发展历史



- 6) 2003-2004年, Google公开了部分GFS和MapReduce思想的细节,以此为基础Doug Cutting等人用了2**年业余时间**实现了DFS和MapReduce机制,使Nutch性能飙升。
  - 7) 2005 年Hadoop 作为 Lucene的子项目 Nutch的一部分正式引入Apache基金会。
- 8) 2006年3月份, Map-Reduce和Nutch Distributed File System (NDFS)分别被纳入到 Hadoop 项目中, Hadoop就此正式诞生,标志着大数据时代来临。
  - 9) 名字来源于Doug Cutting儿子的玩具大象



让天下没有难管的技术

## 1.3 Hadoop 三大发行版本(了解)

Hadoop 三大发行版本: Apache、Cloudera、Hortonworks。

Apache 版本最原始(最基础)的版本,对于入门学习最好。2006

Cloudera 内部集成了很多大数据框架,对应产品 CDH。2008

Hortonworks 文档较好,对应产品 HDP。2011

Hortonworks 现在已经被 Cloudera 公司收购,推出新的品牌 CDP。





#### 1) Apache Hadoop



官网地址: http://hadoop.apache.org

下载地址: https://hadoop.apache.org/releases.html

#### 2) Cloudera Hadoop

官网地址: https://www.cloudera.com/downloads/cdh

下载地址: https://docs.cloudera.com/documentation/enterprise/6/release-

notes/topics/rg cdh 6 download.html

- (1) 2008 年成立的 Cloudera 是最早将 Hadoop 商用的公司,为合作伙伴提供 Hadoop 的 商用解决方案,主要是包括支持、咨询服务、培训。
- (2) 2009 年 Hadoop 的创始人 Doug Cutting 也加盟 Cloudera 公司。Cloudera 产品主要为 CDH,Cloudera Manager,Cloudera Support
- (3) CDH 是 Cloudera 的 Hadoop 发行版,完全开源,比 Apache Hadoop 在兼容性,安全性,稳定性上有所增强。Cloudera 的标价为每年每个节点 **10000 美元**。
- (4) Cloudera Manager 是集群的软件分发及管理监控平台,可以在几个小时内部署好一个 Hadoop 集群,并对集群的节点及服务进行实时监控。

#### 3) Hortonworks Hadoop

官网地址: https://hortonworks.com/products/data-center/hdp/

下载地址: https://hortonworks.com/downloads/#data-platform

- (1) 2011 年成立的 Hortonworks 是雅虎与硅谷风投公司 Benchmark Capital 合资组建。
- (2)公司成立之初就吸纳了大约 25 名至 30 名专门研究 Hadoop 的雅虎工程师,上述工程师均在 2005 年开始协助雅虎开发 Hadoop, 贡献了 Hadoop80%的代码。
- (3) Hortonworks 的主打产品是 Hortonworks Data Platform(HDP),也同样是 100%开源的产品,HDP 除常见的项目外还包括了 **Ambari**,一款开源的安装和管理系统。
  - (4) 2018 年 Hortonworks 目前已经被 Cloudera 公司收购。



## 1.4 Hadoop 优势(4 高)



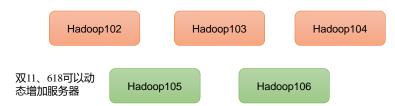
### Hadoop优势 (4高)



1)高可靠性: Hadoop底层维护多个数据副本,所以即使Hadoop某个计算元素或存储出现故障,也不会导致数据的丢失。



2) 高扩展性:在集群间分配任务数据,可方便的扩展数以干计的节点。



动态增加:也就是不用停止hadoop102,hadoop103,hadoop104就可以增加105,106,



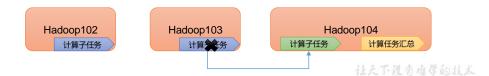
### Hadoop优势 (4高)



3)高效性:在MapReduce的思想下,Hadoop是并行工作的,以加快任务处理速度。



4) 高容错性:能够自动将失败的任务重新分配。





## 1.5 Hadoop 组成(面试重点)



Hadoop1.x、2.x、3.x区别

⊎尚硅谷

hadoop1.X与hadoop2.X之间的区别?

在进进行计算的时候,分配多少内存(资源调度)

MapReduce (计算+资源调度)

HDFS(数据存储)

Common (辅助工具)

MapReduce ( 计算 )

Yarn (资源调度)

HDFS (数据存储)

Common (辅助工具)

源的调度,耦合性较大。 在Hadoop2.x时代,增

在 Hadoop1.x 时代,

Hadoop中的MapReduce同

时处理业务逻辑运算和资

加了Yarn。Yarn只负责

资源的调度,

MapReduce 只负责运算。 Hadoop3.x在组成上没

有变化。

Hadoop1.x组成

Hadoop2.x组成

有200T的资料,分dou'cun'chu成400个服务器存储,每台服务器存储1T数据,问题是数据存储在什么位置,具体的存储数据就是DataNode

### 1.5.1 HDFS 架构概述

Hadoop Distributed File System,简称 HDFS,是一个分布式文件系统。



### HDFS架构概述



1) NameNode (nn):存储文件的元数据,如文件名,文件目录结构,文件属性(生成时间、副本数、文件权限),以及每个文件的块列表和块所在的DataNode等。





2) DataNode(dn): 在本地文件系统存储文件块数据,以及块数据的校验和





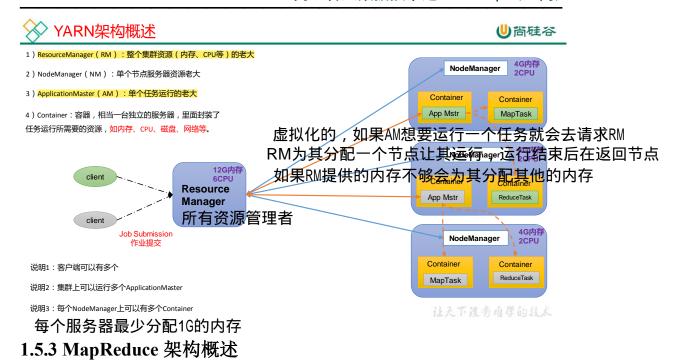
3) Secondary NameNode(2nn):每隔一段时间对NameNode元数据备份。

31子不没有难怪的技术

## 1.5.2 YARN 架构概述

Yet Another Resource Negotiator 简称 YARN,另一种资源协调者,是 Hadoop 的资源管理器。





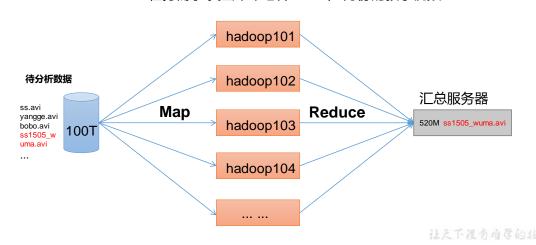
MapReduce 将计算过程分为两个阶段: Map 和 Reduce

- 1) Map 阶段并行处理输入数据
- 2) Reduce 阶段对 Map 结果进行汇总



⊎尚硅谷

任务需求:找出宋宋老师2015年5月份的教学视频



想要找出特定的数据,在每台服务器上寻找想要的结果,将每台服务器找到的结果返回到 返回到汇总服务器上

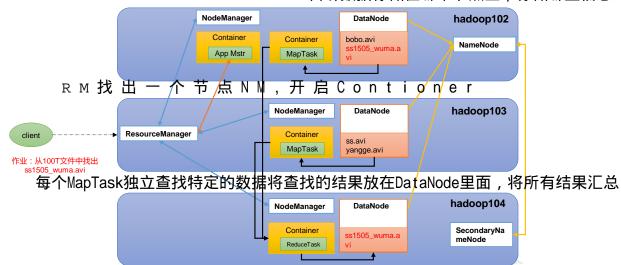


1.5.4 HDFS、YARN、MapReduce 三者关系

2NN:相当于秘书

DataNode:负责数据的存储高硅谷 🧩 HDFS、YARN、MapReduce三者关系

NameNode:告诉数据存储在哪个节点上,存储哪些信息

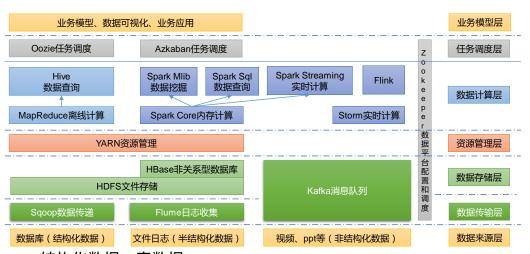


### 1.6 大数据技术生态体系



大数据技术生态体系

⋓尚硅谷



结构化数据:表数据

非结构化数据:比如:文本,图像,视频图中涉及的技术名词解释如下:

- 1) Sqoop: Sqoop 是一款开源的工具,主要用于在 Hadoop、Hive 与传统的数据库 (MySQL) 间进行数据的传递,可以将一个关系型数据库(例如 : MySQL, Oracle 等)中的数据导进 到 Hadoop 的 HDFS 中,也可以将 HDFS 的数据导进到关系型数据库中。
- 2) Flume: Flume 是一个高可用的,高可靠的,分布式的海量日志采集、聚合和传输的系统, Flume 支持在日志系统中定制各类数据发送方,用于收集数据;
- 3) Kafka: Kafka 是一种高吞吐量的分布式发布订阅消息系统;

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网

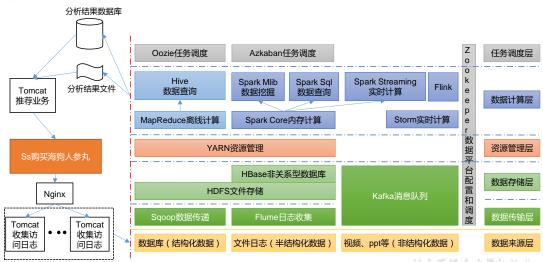


- 4) Spark: Spark 是当前最流行的开源大数据内存计算框架。可以基于 Hadoop 上存储的大数据进行计算。
- 5) Flink: Flink 是当前最流行的开源大数据内存计算框架。用于实时计算的场景较多。
- 6) Oozie: Oozie 是一个管理 Hadoop 作业(job)的工作流程调度管理系统。
- 7) Hbase: HBase 是一个分布式的、面向列的开源数据库。HBase 不同于一般的关系数据库,它是一个适合于非结构化数据存储的数据库。
- 8) Hive: Hive 是基于 Hadoop 的一个数据仓库工具,可以将结构化的数据文件映射为一张数据库表,并提供简单的 SQL 查询功能,可以将 SQL 语句转换为 MapReduce 任务进行运行。其优点是学习成本低,可以通过类 SQL 语句快速实现简单的 MapReduce 统计,不必开发专门的 MapReduce 应用,十分适合数据仓库的统计分析。
- 9) ZooKeeper: 它是一个针对大型分布式系统的可靠协调系统,提供的功能包括: 配置维护、名字服务、分布式同步、组服务等。

## 1.7 推荐系统框架图







让大下没有难尽的技术

## 第2章 Hadoop 运行环境搭建(开发重点)

## 2.1 模板虚拟机环境准备

0) 安装模板虚拟机, IP 地址 192.168.10.100、主机名称 hadoop100、内存 4G、硬盘 50G



况



#### 1) hadoop100 虚拟机配置要求如下(本文 Linux 系统全部以 CentOS-7.5-x86-1804 为例)

(1) 使用 yum 安装需要虚拟机可以正常上网, yum 安装前可以先测试下虚拟机联网情

```
[root@hadoop100 ~]# ping www.baidu.com
PING www.baidu.com (14.215.177.39) 56(84) bytes of data.
64 bytes from 14.215.177.39 (14.215.177.39): icmp_seq=1
ttl=128 time=8.60 ms
64 bytes from 14.215.177.39 (14.215.177.39): icmp_seq=2
ttl=128 time=7.72 ms
```

(2) 安装 epel-release

注: Extra Packages for Enterprise Linux 是为"红帽系"的操作系统提供额外的软件包,适用于 RHEL、CentOS 和 Scientific Linux。相当于是一个软件仓库,大多数 rpm 包在官方 repository 中是找不到的)

[root@hadoop100 ~]# yum install -y epel-release

(3)注意:如果 Linux 安装的是最小系统版,还需要安装如下工具;如果安装的是 Linux

#### 桌面标准版,不需要执行如下操作

▶ net-tool: 工具包集合,包含 ifconfig 等命令

[root@hadoop100 ~]# yum install -y net-tools

➤ vim: 编辑器

[root@hadoop100 ~] # yum install -y vim

2) 关闭防火墙,关闭防火墙开机自启

```
[root@hadoop100 ~]# systemctl stop firewalld
[root@hadoop100 ~]# systemctl disable firewalld.service
```

注意:在企业开发时,通常单个服务器的防火墙时关闭的。公司整体对外会设置非常安

#### 全的防火墙

3) 创建 atguigu 用户,并修改 atguigu 用户的密码

```
[root@hadoop100 ~]# useradd atguigu
[root@hadoop100 ~]# passwd atguigu
```

4) 配置 atguigu 用户具有 root 权限,方便后期加 sudo 执行 root 权限的命令

[root@hadoop100 ~]# vim /etc/sudoers

修改/etc/sudoers 文件, 在%wheel 这行下面添加一行, 如下所示:

```
## Allow root to run any commands anywhere
root ALL=(ALL) ALL

## Allows people in group wheel to run all commands
%wheel ALL=(ALL) ALL
```



atguigu ALL=(ALL) NOPASSWD:ALL

注意: atguigu 这一行不要直接放到 root 行下面,因为所有用户都属于 wheel 组,你先配置了 atguigu 具有免密功能,但是程序执行到%wheel 行时,该功能又被覆盖回需要密码。所以 atguigu 要放到%wheel 这行下面。

#### 5) 在/opt 目录下创建文件夹,并修改所属主和所属组

(1) 在/opt 目录下创建 module、software 文件夹

```
[root@hadoop100 ~]# mkdir /opt/module
[root@hadoop100 ~]# mkdir /opt/software
```

(2) 修改 module、software 文件夹的所有者和所属组均为 atguigu 用户

```
[root@hadoop100 ~]# chown atguigu:atguigu /opt/module
[root@hadoop100 ~]# chown atguigu:atguigu /opt/software
```

(3) 查看 module、software 文件夹的所有者和所属组

```
[root@hadoop100 ~]# cd /opt/
[root@hadoop100 opt]# ll
总用量 12
drwxr-xr-x. 2 atguigu atguigu 4096 5月 28 17:18 module
drwxr-xr-x. 2 root root 4096 9月 7 2017 rh
drwxr-xr-x. 2 atguigu atguigu 4096 5月 28 17:18 software
```

#### 6) 卸载虚拟机自带的 JDK

### 注意: 如果你的虚拟机是最小化安装不需要执行这一步。

```
[root@hadoop100 ~]# rpm -qa | grep -i java | xargs -n1 rpm -e
--nodeps
```

- rpm -qa: 查询所安装的所有 rpm 软件包
- ▶ grep -i: 忽略大小写
- > xargs -n1:表示每次只传递一个参数
- ➤ rpm -e -nodeps: 强制卸载软件

#### 7) 重启虚拟机

[root@hadoop100 ~]# reboot

## 2.2 克隆虚拟机

1) 利用模板机 hadoop100,克隆三台虚拟机:hadoop102 hadoop103 hadoop104

注意: 克隆时, 要先关闭 hadoop100

- 2) 修改克隆机 IP,以下以 hadoop102 举例说明
  - (1) 修改克隆虚拟机的静态 IP

```
[root@hadoop100 ~]# vim /etc/sysconfig/network-scripts/ifcfg-
ens33
```

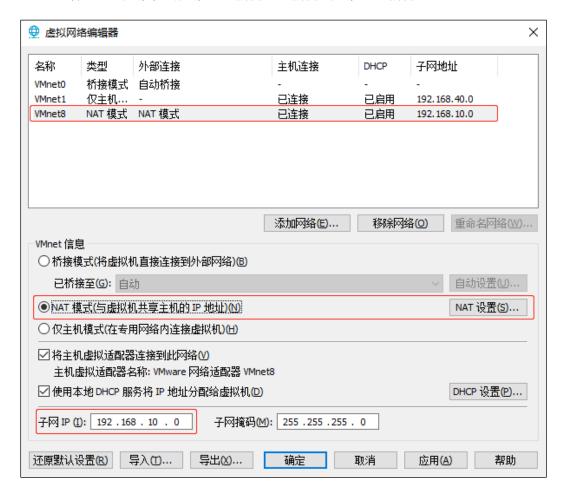
改成

```
DEVICE=ens33
TYPE=Ethernet
```

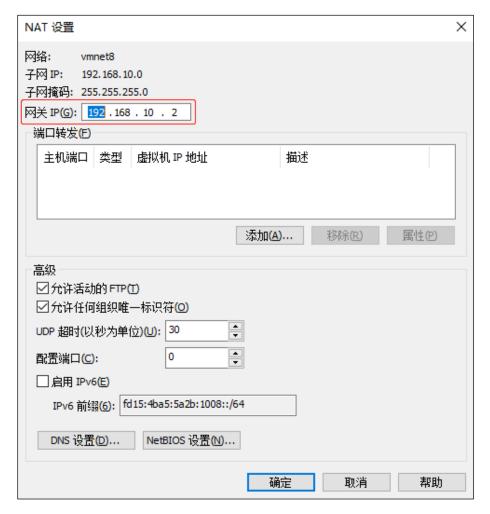


ONBOOT=yes
BOOTPROTO=static
NAME="ens33"
IPADDR=192.168.10.102
PREFIX=24
GATEWAY=192.168.10.2
DNS1=192.168.10.2

(2) 查看 Linux 虚拟机的虚拟网络编辑器,编辑->虚拟网络编辑器->VMnet8

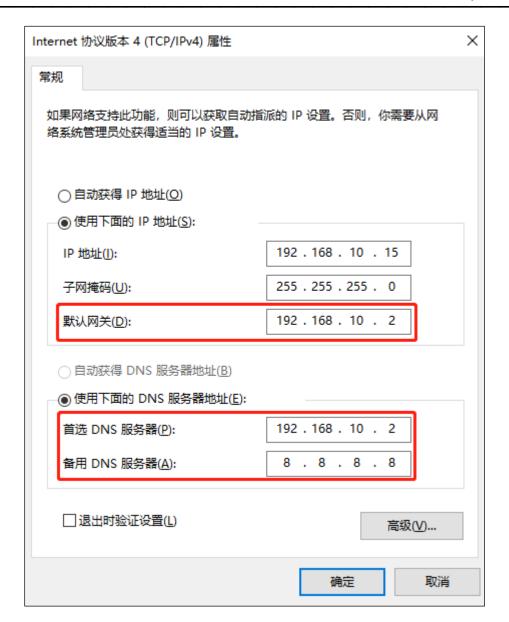






(3) 查看 Windows 系统适配器 VMware Network Adapter VMnet8 的 IP 地址





(4) 保证 Linux 系统 ifcfg-ens33 文件中 IP 地址、虚拟网络编辑器地址和 Windows 系统 VM8 网络 IP 地址相同。

#### 3)修改克隆机主机名,以下以 hadoop102 举例说明

(1) 修改主机名称

```
[root@hadoop100 ~] # vim /etc/hostname hadoop102

(2) 配置 Linux 克隆机主机名称映射 hosts 文件, 打开/etc/hosts
[root@hadoop100 ~] # vim /etc/hosts
添加如下内容

192.168.10.100 hadoop100
192.168.10.101 hadoop101
192.168.10.102 hadoop102
192.168.10.103 hadoop103
192.168.10.104 hadoop104
```

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



```
192.168.10.105 hadoop105
192.168.10.106 hadoop106
192.168.10.107 hadoop107
192.168.10.108 hadoop108
```

### 4) 重启克隆机 hadoop102

[root@hadoop100 ~]# reboot

- 5) 修改 windows 的主机映射文件(hosts 文件)
  - (1) 如果操作系统是 window7, 可以直接修改
  - (a) 进入 C:\Windows\System32\drivers\etc 路径
  - (b) 打开 hosts 文件并添加如下内容, 然后保存

```
192.168.10.100 hadoop100
192.168.10.101 hadoop101
192.168.10.102 hadoop102
192.168.10.103 hadoop103
192.168.10.104 hadoop104
192.168.10.105 hadoop105
192.168.10.106 hadoop106
192.168.10.107 hadoop107
192.168.10.108 hadoop108
```

- (2) 如果操作系统是 window10, 先拷贝出来, 修改保存以后, 再覆盖即可
- (a) 进入 C:\Windows\System32\drivers\etc 路径
- (b) 拷贝 hosts 文件到桌面
- (c) 打开桌面 hosts 文件并添加如下内容

```
192.168.10.100 hadoop100
192.168.10.101 hadoop101
192.168.10.102 hadoop102
192.168.10.103 hadoop103
192.168.10.104 hadoop104
192.168.10.105 hadoop105
192.168.10.106 hadoop106
192.168.10.107 hadoop107
192.168.10.108 hadoop108
```

(d) 将桌面 hosts 文件覆盖 C:\Windows\System32\drivers\etc 路径 hosts 文件

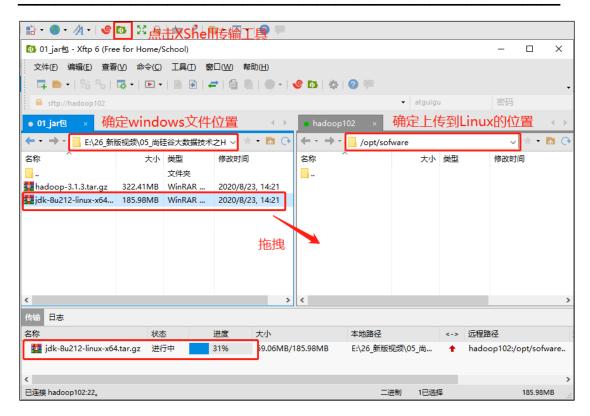
## 2.3 在 hadoop102 安装 JDK

#### 1) 卸载现有 JDK

注意:安装 JDK 前,一定确保提前删除了虚拟机自带的 JDK。详细步骤见问文档 3.1 节中卸载 JDK 步骤。

2) 用 XShell 传输工具将 JDK 导入到 opt 目录下面的 software 文件夹下面





#### 3) 在 Linux 系统下的 opt 目录中查看软件包是否导入成功

[atguigu@hadoop102 ~]\$ ls /opt/software/ 看到如下结果:

jdk-8u212-linux-x64.tar.gz

#### 4) 解压 JDK 到/opt/module 目录下

[atguigu@hadoop102 software]\$ tar -zxvf jdk-8u212-linuxx64.tar.gz -C /opt/module/

#### 5) 配置 JDK 环境变量

(1) 新建/etc/profile.d/my\_env.sh 文件

[atguigu@hadoop102 ~]\$ sudo vim /etc/profile.d/my\_env.sh

添加如下内容

#JAVA\_HOME
export JAVA\_HOME=/opt/module/jdk1.8.0\_212
export PATH=\$PATH:\$JAVA HOME/bin

(2) 保存后退出

:wq

(3) source 一下/etc/profile 文件,让新的环境变量 PATH 生效

[atguigu@hadoop102 ~]\$ source /etc/profile

#### 6) 测试 JDK 是否安装成功

[atguigu@hadoop102 ~]\$ java -version

如果能看到以下结果,则代表 Java 安装成功。

java version "1.8.0 212"



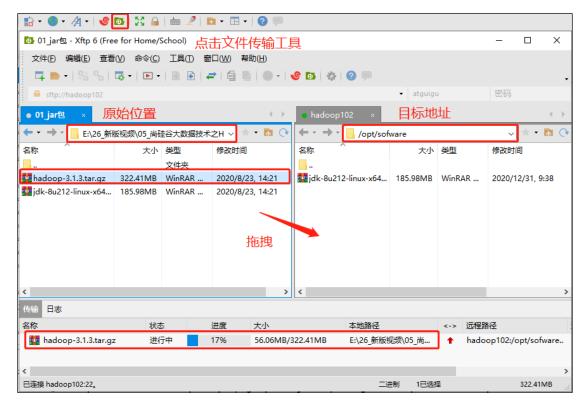
注意: 重启(如果 java -version 可以用就不用重启)

[atguigu@hadoop102 ~]\$ sudo reboot

## 2.4 在 hadoop102 安装 Hadoop

Hadoop 下载地址: <a href="https://archive.apache.org/dist/hadoop/common/hadoop-3.1.3/">https://archive.apache.org/dist/hadoop/common/hadoop-3.1.3/</a>

1) 用 XShell 文件传输工具将 hadoop-3.1.3.tar.gz 导入到 opt 目录下面的 software 文件夹下面



2) 进入到 Hadoop 安装包路径下

[atguigu@hadoop102 ~]\$ cd /opt/software/

3)解压安装文件到/opt/module 下面

[atguigu@hadoop102 software]\$ tar -zxvf hadoop-3.1.3.tar.gz -C
/opt/module/

4) 查看是否解压成功

[atguigu@hadoop102 software]\$ ls /opt/module/ hadoop-3.1.3

- 5) 将 Hadoop 添加到环境变量
  - (1) 获取 Hadoop 安装路径

[atguigu@hadoop102 hadoop-3.1.3]\$ pwd /opt/module/hadoop-3.1.3

(2) 打开/etc/profile.d/my\_env.sh 文件

[atguigu@hadoop102 hadoop-3.1.3]\$ sudo vim
/etc/profile.d/my\_env.sh



➤ 在 my\_env.sh 文件末尾添加如下内容: (shift+g)

```
#HADOOP_HOME
export HADOOP_HOME=/opt/module/hadoop-3.1.3
export PATH=$PATH:$HADOOP_HOME/bin
export PATH=$PATH:$HADOOP_HOME/sbin
```

- ▶ 保存并退出: :wq
- (3) 让修改后的文件生效

[atguigu@hadoop102 hadoop-3.1.3]\$ source /etc/profile

#### 6) 测试是否安装成功

```
[atguigu@hadoop102 hadoop-3.1.3]$ hadoop version Hadoop 3.1.3
```

7) 重启(如果 Hadoop 命令不能用再重启虚拟机)

[atguigu@hadoop102 hadoop-3.1.3]\$ sudo reboot

## 2.5 Hadoop 目录结构

1) 查看 Hadoop 目录结构

```
[atguigu@hadoop102 hadoop-3.1.3]$ 11
总用量 52
drwxr-xr-x. 2 atguigu atguigu 4096 5月 22 2017 bin
drwxr-xr-x. 3 atguigu atguigu 4096 5月 22 2017 etc
drwxr-xr-x. 2 atguigu atguigu 4096 5月 22 2017 include
drwxr-xr-x. 3 atguigu atguigu 4096 5月 22 2017 lib
drwxr-xr-x. 2 atguigu atguigu 4096 5月 22 2017 libexec
-rw-r--r-. 1 atguigu atguigu 15429 5月 22 2017 LICENSE.txt
-rw-r--r-. 1 atguigu atguigu 101 5月 22 2017 NOTICE.txt
-rw-r--r-. 1 atguigu atguigu 1366 5月 22 2017 README.txt
drwxr-xr-x. 2 atguigu atguigu 4096 5月 22 2017 sbin
drwxr-xr-x. 4 atguigu atguigu 4096 5月 22 2017 share
```

#### 2) 重要目录

- (1) bin 目录:存放对 Hadoop 相关服务(hdfs, yarn, mapred)进行操作的脚本
- (2) etc 目录: Hadoop 的配置文件目录, 存放 Hadoop 的配置文件
- (3) lib 目录:存放 Hadoop 的本地库(对数据进行压缩解压缩功能)
- (4) sbin 目录: 存放启动或停止 Hadoop 相关服务的脚本
- (5) share 目录:存放 Hadoop 的依赖 jar 包、文档、和官方案例

## 第3章 Hadoop 运行模式

- 1) Hadoop 官方网站: http://hadoop.apache.org/
- 2) Hadoop 运行模式包括: 本地模式、伪分布式模式以及完全分布式模式。
  - ▶ 本地模式: 单机运行,只是用来演示一下官方案例。生产环境不用。



- ▶ **伪分布式模式:** 也是单机运行,但是具备 Hadoop 集群的所有功能,一台服务器模拟一个分布式的环境。个别缺钱的公司用来测试,生产环境不用。
- ▶ 完全分布式模式: 多台服务器组成分布式环境。生产环境使用。

## 3.1 本地运行模式(官方 WordCount)

1) 创建在 hadoop-3.1.3 文件下面创建一个 weinput 文件夹

[atguigu@hadoop102 hadoop-3.1.3]\$ mkdir wcinput

2) 在 weinput 文件下创建一个 word.txt 文件

[atguigu@hadoop102 hadoop-3.1.3]\$ cd wcinput

3) 编辑 word.txt 文件

[atguigu@hadoop102 wcinput] \$ vim word.txt

▶ 在文件中输入如下内容

```
hadoop yarn
hadoop mapreduce
atguigu
atguigu
```

- ▶ 保存退出::wq
- 4) 回到 Hadoop 目录/opt/module/hadoop-3.1.3
- 5) 执行程序

```
[atguigu@hadoop102 hadoop-3.1.3]$ hadoop jar share/hadoop/mapreduce/hadoop-mapreduce-examples-3.1.3.jar wordcount wcinput wcoutput
```

6) 查看结果

[atguigu@hadoop102 hadoop-3.1.3]\$ cat wcoutput/part-r-00000 看到如下结果:

```
atguigu 2
hadoop 2
mapreduce 1
yarn 1
```

## 3.2 完全分布式运行模式(开发重点)

分析:

- 1)准备3台客户机(关闭防火墙、静态 IP、主机名称)
- 2) 安装 JDK
- 3) 配置环境变量
- 4) 安装 Hadoop
- 5) 配置环境变量
- 6) 配置集群



- 7) 单点启动
- 8) 配置 ssh
- 9) 群起并测试集群

### 3.2.1 虚拟机准备

详见 2.1、2.2 两节。

## 3.2.2 编写集群分发脚本 xsync

- 1) scp (secure copy) 安全<mark>拷贝</mark>
  - (1) scp 定义

scp 可以实现服务器与服务器之间的数据拷贝。(from server1 to server2)

(2) 基本语法

 scp
 -r
 \$pdir/\$fname
 \$user@\$host:\$pdir/\$fname

 命令
 递归
 要拷贝的文件路径/名称
 目的地用户@主机:目的地路径/名称

- (3) 案例实操
  - ▶ <mark>前提:</mark> 在 hadoop102、hadoop103、hadoop104 都已经创建好的/opt/module、

/opt/software 两个目录,并且已经把这两个目录修改为 atguigu:atguigu

[atguigu@hadoop102 ~]\$ sudo chown atguigu:atguigu -R
/opt/module

(a) 在 hadoop102 上,将 hadoop102 中/opt/module/jdk1.8.0\_212 目录拷贝到 hadoop103 上。

[atguigu@hadoop102 ~]\$ scp -r /opt/module/jdk1.8.0\_212 atguigu@hadoop103:/opt/module

(b) 在 hadoop103 上,将 hadoop102 中/opt/module/hadoop-3.1.3 目录拷贝到 hadoop103 上。

```
[atguigu@hadoop103 ~]$ scp -r
atguigu@hadoop102:/opt/module/hadoop-3.1.3 /opt/module/
```

(c) 在 hadoop103 上操作,将 hadoop102 中/opt/module 目录下所有目录拷贝到 hadoop104 上。

### 2) rsync 远程同步工具

rsync 主要用于备份和镜像。具有速度快、避免复制相同内容和支持符号链接的优点。

rsync 和 scp 区别: 用 rsync 做文件的复制要比 scp 的速度快, rsync 只对差异文件做更新。scp 是把所有文件都复制过去。

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



(1) 基本语法

rsync -av \$pdir/\$fname \$user@\$host:\$pdir/\$fname 命令 选项参数 要拷贝的文件路径/名称 目的地用户@主机:目的地路径/名称 选项参数说明

选项	功能
-a	归档拷贝
-V	显示复制过程

- (2) 案例实操
- (a) 删除 hadoop103 中/opt/module/hadoop-3.1.3/wcinput

```
[atguigu@hadoop103 hadoop-3.1.3] rm -rf wcinput/
```

(b) 同步 hadoop102 中的/opt/module/hadoop-3.1.3 到 hadoop103

```
[atguigu@hadoop102 module]$ rsync -av hadoop-3.1.3/
atguigu@hadoop103:/opt/module/hadoop-3.1.3/
```

#### 3) xsync 集群分发脚本

- (1) 需求:循环复制文件到所有节点的相同目录下
- (2) 需求分析:
  - (a) rsync 命令原始拷贝:

```
rsync -av /opt/module atguigu@hadoop103:/opt/
```

(b) 期望脚本:

xsync 要同步的文件名称

(c) 期望脚本在任何路径都能使用(脚本放在声明了全局环境变量的路径)

```
[atguigu@hadoop102 ~]$ echo $PATH /usr/local/bin:/usr/bin:/usr/local/sbin:/home/atguigu/.local/bin:/home/atguigu/bin:/opt/module/jdk1.8.0_212/bin
```

- (3) 脚本实现
  - (a) 在/home/atguigu/bin 目录下创建 xsync 文件

```
[atguigu@hadoop102 opt]$ cd /home/atguigu
[atguigu@hadoop102 ~]$ mkdir bin
[atguigu@hadoop102 ~]$ cd bin
[atguigu@hadoop102 bin]$ vim xsync
```

在该文件中编写如下代码

```
#!/bin/bash

先点击i/0进入插入模式,在将所有代码粘贴到里面

#1. 判断参数个数

if [ $# -lt 1 ] 参数个数小于1

then echo Not Enough Arguement!

exit;

fi
```



```
#2. 遍历集群所有机器
for host in hadoop102 hadoop103 hadoop104
   echo ======== $host ==
   #3. 遍历所有目录, 挨个发送
   for file in $@
   do
      #4. 判断文件是否存在
                          midir 103 创建文件103,如果103文件存在会报错
      if [ -e $file ]
         then
                          midir -p 103 即使103文件存在也不会报错
            #5. 获取父目录
            pdir=$(cd -P $(dirname $file); pwd)
            #6. 获取当前文件的名称
            fname=$(basename $file)
            ssh $host "mkdir -p $pdir"
            rsync -av $pdir/$fname $host:$pdir
         else
            echo $file does not exists!
      fi
   done
done
(b) 修改脚本 xsync 具有执行权限
[atguigu@hadoop102 bin]$ chmod +x xsync
(c) 测试脚本
[atguigu@hadoop102 ~]$ xsync /home/atguigu/bin
(d) 将脚本复制到/bin 中,以便全局调用
[atguigu@hadoop102 bin]$ sudo cp xsync /bin/
(e) 同步环境变量配置 (root 所有者)
[atguigu@hadoop102 ~]$ sudo ./bin/xsync
/etc/profile.d/my_env.sh
                          绝对路径
注意:如果用了 sudo,那么 xsync 一定要给它的路径补全。
让环境变量生效
[atguigu@hadoop103 bin]$ source /etc/profile
[atguigu@hadoop104 opt]$ source /etc/profile
```

## 3.2.3 SSH 无密登录配置

### 1) 配置 ssh

(1) 基本语法

ssh 另一台电脑的 IP 地址

(2) ssh 连接时出现 Host key verification failed 的解决方法

[atguigu@hadoop102 ~]\$ ssh hadoop103

▶ 如果出现如下内容

Are you sure you want to continue connecting (yes/no)?



- ▶ 输入 yes, 并回车
- (3) 退回到 hadoop102

[atguigu@hadoop103 ~]\$ exit

#### 2) 无密钥配置

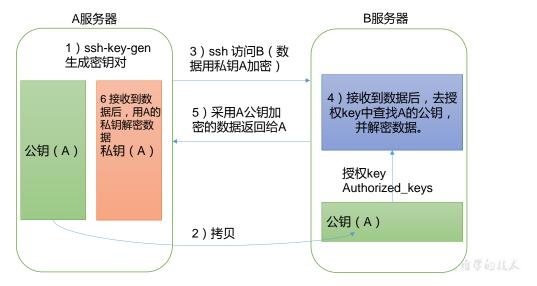
(1) 免密登录原理



免密登录原理

如果B服务器想要访问A服务器





#### (2) 生成公钥和私钥

```
[atguigu@hadoop102 .ssh]$ pwd
/home/atguigu/.ssh

[atguigu@hadoop102 .ssh]$ ssh-keygen -t rsa
```

然后敲(三个回车),就会生成两个文件 id rsa(私钥)、id rsa.pub(公钥)

(3) 将公钥拷贝到要免密登录的目标机器上

```
[atguigu@hadoop102 .ssh]$ ssh-copy-id hadoop102 [atguigu@hadoop102 .ssh]$ ssh-copy-id hadoop103 102可以免密登录103,1004 [atguigu@hadoop102 .ssh]$ ssh-copy-id hadoop104
```

### 注意: 在对103,104机器做相同的操作

还需要在 hadoop103 上采用 atguigu 账号配置一下无密登录到 hadoop102、hadoop103、

#### hadoop104 服务器上。

还需要在 hadoop104 上采用 atguigu 账号配置一下无密登录到 hadoop102、hadoop103、

#### hadoop104 服务器上。

还需要在 hadoop102 上采用 root 账号,配置一下无密登录到 hadoop102、hadoop103、

#### hadoop104;

3).ssh 文件夹下(~/.ssh)的文件功能解释



known_hosts	记录 ssh 访问过计算机的公钥(public key)
id_rsa	生成的私钥
id_rsa.pub	生成的公钥
authorized_keys	存放授权过的无密登录服务器公钥

## 3.2.4 集群配置

### 1) 集群部署规划

#### 注意:

- ▶ NameNode 和 SecondaryNameNode 不要安装在同一台服务器
- ResourceManager 也很消耗内存,不要和 NameNode、SecondaryNameNode 配置在同一台机器上。

	hadoop102	hadoop103	hadoop104
HDFS	NameNode		SecondaryNameNode
	DataNode	DataNode	DataNode
YARN		ResourceManager	
	NodeManager	NodeManager	NodeManager

#### 2) 配置文件说明

Hadoop 配置文件分两类:默认配置文件和自定义配置文件,只有用户想修改某一默认配置值时,才需要修改自定义配置文件,更改相应属性值。

#### (1) 默认配置文件:

要获取的默认文件	文件存放在 Hadoop 的 jar 包中的位置
[core-default.xml]	hadoop-common-3.1.3.jar/core-default.xml
[hdfs-default.xml]	hadoop-hdfs-3.1.3.jar/hdfs-default.xml
[yarn-default.xml]	hadoop-yarn-common-3.1.3.jar/yarn-default.xml
[mapred-default.xml]	hadoop-mapreduce-client-core-3.1.3.jar/mapred-default.xml

(2) 自定义配置文件:

**core-site.xml、hdfs-site.xml、yarn-site.xml、mapred-site.xml** 四个配置文件存放在 \$HADOOP\_HOME/etc/hadoop 这个路径上,用户可以根据项目需求重新进行修改配置。

### 3) 配置集群

(1) 核心配置文件

#### 配置 core-site.xml

[atguigu@hadoop102 ~]\$ cd \$HADOOP HOME/etc/hadoop



[atguigu@hadoop102 hadoop]\$ vim core-site.xml

文件内容如下:

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<configuration>
   <!-- 指定 NameNode 的地址 -->
   cproperty>
      <name>fs.defaultFS</name>
      <value>hdfs://hadoop102:8020</value>
   </property>
   <!-- 指定 hadoop 数据的存储目录 -->
   cproperty>
      <name>hadoop.tmp.dir</name>
      <value>/opt/module/hadoop-3.1.3/data</value>
   </property>
   <!-- 配置 HDFS 网页登录使用的静态用户为 atguigu -->
   property>
      <name>hadoop.http.staticuser.user
      <value>atguigu</value>
   </property>
</configuration>
```

(2) HDFS 配置文件

#### 配置 hdfs-site.xml

[atguigu@hadoop102 hadoop]\$ vim hdfs-site.xml

文件内容如下:

(3) YARN 配置文件

#### 配置 yarn-site.xml

[atguigu@hadoop102 hadoop]\$ vim yarn-site.xml

文件内容如下:

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
```



```
<configuration>
   <!-- 指定 MR 走 shuffle -->
   property>
      <name>yarn.nodemanager.aux-services</name>
      <value>mapreduce shuffle</value>
   </property>
   <!-- 指定 ResourceManager 的地址-->
   cproperty>
      <name>yarn.resourcemanager.hostname
      <value>hadoop103</value>
   </property>
   <!-- 环境变量的继承 -->
   cproperty>
      <name>yarn.nodemanager.env-whitelist</name>
<value>JAVA HOME, HADOOP COMMON HOME, HADOOP HDFS HOME, HADOOP CO
NF DIR, CLASSPATH PREPEND DISTCACHE, HADOOP YARN HOME, HADOOP MAP
RED HOME</value>
   </property>
</configuration>
```

### (4) MapReduce 配置文件

#### 配置 mapred-site.xml

[atguigu@hadoop102 hadoop]\$ vim mapred-site.xml

文件内容如下:

#### 4) 在集群上分发配置好的 Hadoop 配置文件

[atguigu@hadoop102	hadoop]\$	xsync	/opt/module/hadoop-
3.1.3/etc/hadoop/			

#### 5) 去 103 和 104 上查看文件分发情况

[atguigu@hadoop103	~]\$	cat	/opt/module/hadoop-
3.1.3/etc/hadoop/core-	site.xml		
[atguigu@hadoop104	~]\$	cat	/opt/module/hadoop-
3.1.3/etc/hadoop/core-	site.xml		

## 3.2.5 群起集群

#### 1) 配置 workers

[atguigu@hadoop102	hadoop]\$	vim	/opt/module/hadoop-
3.1.3/etc/hadoop/workers			

在该文件中增加如下内容:



hadoop102 hadoop103

hadoop104

注意:该文件中添加的内容结尾不允许有空格,文件中不允许有空行。

同步所有节点配置文件

[atguigu@hadoop102 hadoop]\$ xsync /opt/module/hadoop-3.1.3/etc

#### 2) 启动集群

(1)如果集群是第一次启动,需要在 hadoop102 节点格式化 NameNode (注意:格式化 NameNode,会产生新的集群 id,导致 NameNode 和 DataNode 的集群 id 不一致,集群找不到已往数据。如果集群在运行过程中报错,需要重新格式化 NameNode 的话,一定要先停止 namenode 和 datanode 进程,并且要删除所有机器的 data 和 logs 目录,然后再进行格式化。)

[atguigu@hadoop102 hadoop-3.1.3] hdfs namenode -format

(2) 启动 HDFS 11: 查看当前文件夹的文件

[atguigu@hadoop102 hadoop-3.1.3]\$ sbin/start-dfs.sh

(3) 在配置了 ResourceManager 的节点(hadoop103)启动 YARN

[atguigu@hadoop103 hadoop-3.1.3]\$ sbin/start-yarn.sh

- (4) Web 端查看 HDFS 的 NameNode
  - (a) 浏览器中输入: <a href="http://hadoop102:9870">http://hadoop102:9870</a>
  - (b) 查看 HDFS 上存储的数据信息
- (5) Web 端查看 YARN 的 ResourceManager
  - (a) 浏览器中输入: <a href="http://hadoop103:8088">http://hadoop103:8088</a>
  - (b) 查看 YARN 上运行的 Job 信息

右上角UNitites点第一个就可以得到的根目录的文件,后面上传的文件会在这上上面显示,download进行下载

### 3) 集群基本测试

- (1) 上传文件到集群
- ▶ 上传小文件

[atguigu@hadoop102 ~]\$ hadoop fs -mkdir /input 在根目录下创建文件input [atguigu@hadoop102 ~]\$ hadoop fs -put \$HADOOP\_HOME/wcinput/word.txt /input

▶ 上传大文件

- (2) 上传文件后查看文件存放在什么位置
- ▶ 查看 HDFS 文件存储路径

[atguigu@hadoop102 subdir0]\$ pwd - 步 的 点 击 /opt/module/hadoop-3.1.3/data/dfs/data/current/BP-1436128598-192.168.10.102-1610603650062/current/finalized/subdir0/subdir0



#### ▶ 查看 HDFS 在磁盘存储文件内容

```
[atguigu@hadoop102 subdir0]$ cat blk_1073741825
hadoop yarn
hadoop mapreduce
atguigu
atguigu
```

#### (3) 拼接

#### 三台服务器上都会存储上传的数据

```
-rw-rw-r--. 1 atguigu atguigu 134217728 5 月 23 16:01 blk_1073741836
-rw-rw-r--. 1 atguigu atguigu 1048583 5 月 23 16:01 blk_1073741836_1012.meta
-rw-rw-r--. 1 atguigu atguigu 63439959 5 月 23 16:01 blk_1073741837
-rw-rw-r--. 1 atguigu atguigu 495635 5 月 23 16:01 blk_1073741837_1013.meta
[atguigu@hadoop102 subdir0]$ cat blk_1073741836>>tmp.tar.gz tar.gz压缩文件
[atguigu@hadoop102 subdir0]$ cat blk_1073741837>>tmp.tar.gz
[atguigu@hadoop102 subdir0]$ tar -zxvf tmp.tar.gz
```

#### (4) 下载

```
[atguigu@hadoop104 software]$ hadoop fs -get /jdk-8u212-linux-x64.tar.gz ./
```

#### (5) 执行 wordcount 程序

```
[atguigu@hadoop102 hadoop-3.1.3]$ hadoop jar share/hadoop/mapreduce/hadoop-mapreduce-examples-3.1.3.jar wordcount /input /output 看网站上的文件的内容就是想要的结果
```

### 3.2.6 配置历史服务器

为了查看程序的历史运行情况,需要配置一下历史服务器。具体配置步骤如下:

### 1) 配置 mapred-site.xml

```
[atguigu@hadoop102 hadoop]$ vim mapred-site.xml
```

在该文件里面增加如下配置。

#### 2) 分发配置

```
[atguigu@hadoop102 hadoop]$ xsync $HADOOP_HOME/etc/hadoop/mapred-site.xml
```

### 3) 在 hadoop102 启动历史服务器

[atguigu@hadoop102 hadoop]\$ mapred --daemon start historyserver

#### 4) 查看历史服务器是否启动

[atguigu@hadoop102 hadoop]\$ jps

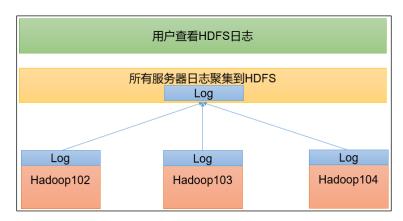


#### 5) 查看 JobHistory

http://hadoop102:19888/jobhistory

### 3.2.7 配置日志的聚集

日志聚集概念:应用运行完成以后,将程序运行日志信息上传到 HDFS 系统上。



日志聚集功能好处:可以方便的查看到程序运行详情,方便开发调试。

注意: 开启日志聚集功能, 需要重新启动 NodeManager 、ResourceManager 和

#### HistoryServer<sub>o</sub>

开启日志聚集功能具体步骤如下:

#### 1) 配置 yarn-site.xml

[atguigu@hadoop102 hadoop]\$ vim yarn-site.xml 在该文件里面增加如下配置。

#### 2) 分发配置

[atguigu@hadoop102 hadoop]\$ xsync \$HADOOP\_HOME/etc/hadoop/yarn-site.xml

#### 3) 关闭 NodeManager 、ResourceManager 和 HistoryServer

```
[atguigu@hadoop103 hadoop-3.1.3]$ sbin/stop-yarn.sh [atguigu@hadoop103 hadoop-3.1.3]$ mapred --daemon stop
```



historyserver

4) 启动 NodeManager 、ResourceManage 和 HistoryServer

[atguigu@hadoop103 ~]\$ start-yarn.sh [atguigu@hadoop102 ~]\$ mapred --daemon start historyserver

5) 删除 HDFS 上已经存在的输出文件

[atguigu@hadoop102 ~]\$ hadoop fs -rm -r /output

6) 执行 WordCount 程序

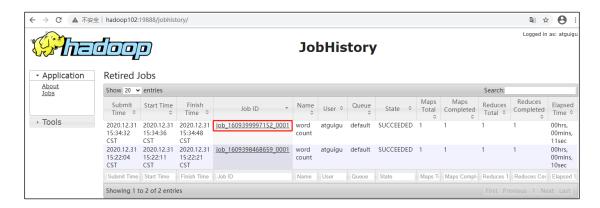
[atguigu@hadoop102 hadoop-3.1.3]\$ hadoop jar share/hadoop/mapreduce/hadoop-mapreduce-examples-3.1.3.jar wordcount /input /output

#### 7) 查看日志

(1) 历史服务器地址

http://hadoop102:19888/jobhistory

(2) 历史任务列表



(3) 查看任务运行日志



(4) 运行日志详情



## 3.2.8 集群启动/停止方式总结

- 1) 各个模块分开启动/停止(配置 ssh 是前提)常用
  - (1) 整体启动/停止 HDFS

```
start-dfs.sh/stop-dfs.sh
```

(2) 整体启动/停止 YARN

start-yarn.sh/stop-yarn.sh

- 2) 各个服务组件逐一启动/停止
  - (1) 分别启动/停止 HDFS 组件

hdfs --daemon start/stop namenode/datanode/secondarynamenode

(2) 启动/停止 YARN

yarn --daemon start/stop resourcemanager/nodemanager

## 3.2.9 编写 Hadoop 集群常用脚本

1) Hadoop 集群启停脚本(包含 HDFS, Yarn, Historyserver): myhadoop.sh

```
[atguigu@hadoop102 ~]$ cd /home/atguigu/bin
[atguigu@hadoop102 bin]$ vim myhadoop.sh
```

▶ 输入如下内容



```
ssh hadoop103 "/opt/module/hadoop-3.1.3/sbin/start-yarn.sh"
    echo " ------ 启动 historyserver ------"
    ssh hadoop102 "/opt/module/hadoop-3.1.3/bin/mapred --daemon start
;;
"stop")
    echo " ------ 关闭 historyserver ------"
    ssh hadoop102 "/opt/module/hadoop-3.1.3/bin/mapred --daemon stop
historyserver"
    ssh hadoop103 "/opt/module/hadoop-3.1.3/sbin/stop-yarn.sh"
    ssh hadoop102 "/opt/module/hadoop-3.1.3/sbin/stop-dfs.sh"
;;
*)
  echo "Input Args Error..."
;;
esac
```

保存后退出,然后赋予脚本执行权限

[atguigu@hadoop102 bin]\$ chmod +x myhadoop.sh

### 2) 查看三台服务器 Java 进程脚本: jpsall

[atguigu@hadoop102 ~]\$ cd /home/atguigu/bin
[atguigu@hadoop102 bin]\$ vim jpsall

▶ 输入如下内容

▶ 保存后退出,然后赋予脚本执行权限

[atguigu@hadoop102 bin]\$ chmod +x jpsall

#### 3) 分发/home/atguigu/bin 目录,保证自定义脚本在三台机器上都可以使用

[atguigu@hadoop102 ~] \$ xsync /home/atguigu/bin/

### 3.2.10 常用端口号说明

端口名称	Hadoop2.x	Hadoop3.x
NameNode 内部通信端口	8020 / 9000	8020 / 9000/9820
NameNode HTTP UI	50070	9870
MapReduce 查看执行任务端口	8088	8088
历史服务器通信端口	19888	19888



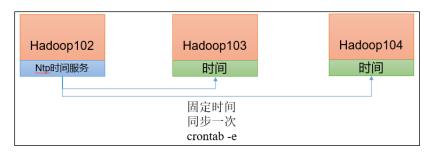
### 3.2.11 集群时间同步

如果服务器在公网环境(能连接外网),可以不采用集群时间同步,因为服务器会定期 和公网时间进行校准;

如果服务器在内网环境,必须要配置集群时间同步,否则时间久了,会产生时间偏差, 导致集群执行任务时间不同步。

#### 1) 需求

找一个机器,作为时间服务器,所有的机器与这台集群时间进行定时的同步,生产环境 根据任务对时间的准确程度要求周期同步。测试环境为了尽快看到效果,采用1分钟同步一次。



#### 2) 时间服务器配置(必须 root 用户)

(1) 查看所有节点 ntpd 服务状态和开机自启动状态

```
[atguigu@hadoop102 ~]$ sudo systemctl status ntpd
[atguigu@hadoop102 ~]$ sudo systemctl start ntpd
[atguigu@hadoop102 ~]$ sudo systemctl is-enabled ntpd
```

(2) 修改 hadoop102 的 ntp.conf 配置文件

```
[atguigu@hadoop102 ~]$ sudo vim /etc/ntp.conf
```

修改内容如下

(a) 修改 1 (授权 192.168.10.0-192.168.10.255 网段上的所有机器可以从这台机器上查询和同步时间)

#restrict 192.168.10.0 mask 255.255.255.0 nomodify notrap

为 restrict 192.168.10.0 mask 255.255.255.0 nomodify notrap

(b) 修改 2 (集群在局域网中,不使用其他互联网上的时间)

```
server 0.centos.pool.ntp.org iburst
server 1.centos.pool.ntp.org iburst
server 2.centos.pool.ntp.org iburst
server 3.centos.pool.ntp.org iburst
```

为

```
#server 0.centos.pool.ntp.org iburst
#server 1.centos.pool.ntp.org iburst
#server 2.centos.pool.ntp.org iburst
```



#server 3.centos.pool.ntp.org iburst

(c)添加3(当该节点丢失网络连接,依然可以采用本地时间作为时间服务器为集群中

的其他节点提供时间同步)

```
server 127.127.1.0 fudge 127.127.1.0 stratum 10
```

(3) 修改 hadoop102 的/etc/sysconfig/ntpd 文件

[atguigu@hadoop102 ~]\$ sudo vim /etc/sysconfig/ntpd

增加内容如下(让硬件时间与系统时间一起同步)

SYNC HWCLOCK=yes

(4) 重新启动 ntpd 服务

[atguigu@hadoop102 ~]\$ sudo systemctl start ntpd

(5) 设置 ntpd 服务开机启动

[atguigu@hadoop102 ~]\$ sudo systemctl enable ntpd

- 3) 其他机器配置(必须 root 用户)
  - (1) 关闭所有节点上 ntp 服务和自启动

```
[atguigu@hadoop103 ~]$ sudo systemctl stop ntpd
[atguigu@hadoop103 ~]$ sudo systemctl disable ntpd
[atguigu@hadoop104 ~]$ sudo systemctl stop ntpd
[atguigu@hadoop104 ~]$ sudo systemctl disable ntpd
```

(2) 在其他机器配置 1 分钟与时间服务器同步一次

[atguigu@hadoop103 ~]\$ sudo crontab -e

编写定时任务如下:

#### \*/1 \* \* \* \* /usr/sbin/ntpdate hadoop102

(3) 修改任意机器时间

[atquiqu@hadoop103 ~]\$ sudo date -s "2021-9-11 11:11:11"

(4) 1 分钟后查看机器是否与时间服务器同步

[atguigu@hadoop103 ~]\$ sudo date

## 第4章 常见错误及解决方案

1) 防火墙没关闭、或者没有启动 YARN

INFO client.RMProxy: Connecting to ResourceManager at hadoop108/192.168.10.108:8032

- 2) 主机名称配置错误
- 3) IP 地址配置错误
- 4) ssh 没有配置好
- 5) root 用户和 atguigu 两个用户启动集群不统一
- 6) 配置文件修改不细心
- 7) 不识别主机名称



```
java.net.UnknownHostException: hadoop102: hadoop102
    at
java.net.InetAddress.getLocalHost(InetAddress.java:1475)
    at
org.apache.hadoop.mapreduce.JobSubmitter.submitJobInternal(JobSubmitter.java:146)
    at org.apache.hadoop.mapreduce.Job$10.run(Job.java:1290)
    at org.apache.hadoop.mapreduce.Job$10.run(Job.java:1287)
    at java.security.AccessController.doPrivileged(Native Method)
at javax.security.auth.Subject.doAs(Subject.java:415)
```

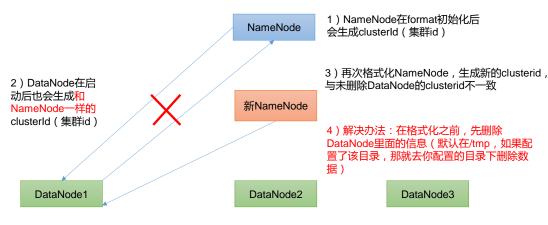
#### 解决办法:

- (1) 在/etc/hosts 文件中添加 192.168.10.102 hadoop102
- (2) 主机名称不要起 hadoop hadoop000 等特殊名称
- 8) DataNode 和 NameNode 进程同时只能工作一个。





### DataNode和NameNode进程同时只能有一个工作问题分析



让天下潜南难怪的技术

- 9) 执行命令不生效, 粘贴 Word 中命令时, 遇到-和长--没区分开。导致命令失效解决办法: 尽量不要粘贴 Word 中代码。
- 10) jps 发现进程已经没有,但是重新启动集群,提示进程已经开启。

原因是在 Linux 的根目录下/tmp 目录中存在启动的进程临时文件,将集群相关进程删除掉,再重新启动集群。

11) jps 不生效

原因:全局变量 hadoop java 没有生效。解决办法:需要 source /etc/profile 文件。

12) 8088 端口连接不上

[atguigu@hadoop102 桌面]\$ cat /etc/hosts

注释掉如下代码

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



#127.0.0.1 localhost localhost.localdomain localhost4 localhost4.localdomain4

#::1 hadoop102